스케줄링 알고리즘을 활용한 다중 사용자 LLM API 요청 관리 시스템

Multi-User LLM API Request Management System Using Scheduling Algorithms

발표자	서민지
소속	홍익대학교 컴퓨터공학과 4학년
지도교수	이장호 교수님
발표일	2026년 5월

목차

1 **연구 배경 및 목적**
문제 정의 · 연구 질문

2 **시스템 설계**
아키텍처 · 4계층 구조

3 **구현**
4가지 스케줄링 알고리즘 · 등급 체계

4 **실험 결과**
성능 비교 · MLFQ 선점형 · WFQ 차등 서비스

5 **결론**
연구 요약 · 한계 · 향후 과제

연구 배경 및 목적

문제 상황

- LLM API 서비스 다중 사용자 동시 접속 급증
- 요청 처리 순서·우선순위 기준 없음
- 특정 사용자 독점 시 다른 사용자 대기 지연
- 구독 등급별 차등 서비스 불가

→

제안 접근법

OS 스케줄링 알고리즘을
LLM API 요청 관리에 적용

FCFS · Priority · MLFQ · WFQ

4가지 알고리즘 구현 및 비교

연구 질문 (Research Questions)

RQ1 OS 스케줄링 알고리즘을 LLM API 환경에 구현할 수 있는가?

RQ2 알고리즘별 성능(대기시간)은 어떻게 다른가?

RQ3 사용자 공정성(JFI)은 알고리즘별로 어떻게 차이나는가?

시스템 아키텍처

클라이언트 계층
REST Client · 대시보드

↓

API 계층
Express.js · Rate Limiter(전처리) · 요청 접수

↓

스케줄러 계층
FCFS · Priority · MLFQ · WFQ

↓

저장소 / LLM 계층
메모리 큐 · JSON 파일 로그 · ollama

기술 스택

- Node.js 22
- Express.js
- JavaScript
- 메모리 큐 + JSON 로그
- ollama (LLM)

스케줄링 알고리즘 비교

FCFS

First-Come, First-Served

도착 순서대로 처리

핵심: 단순, 공평, 순서 보장

Priority

Priority Scheduling

긴급한 요청 먼저 처리

핵심: URGENT > HIGH > NORMAL > LOW

MLFQ

Multi-Level Feedback Queue

짧은 요청 우선 처리

핵심: 큐 수준에 따른 시간 할당량

WFQ

Weighted Fair Queuing

등급별 차등 서비스

핵심: Enterprise > Premium > Standard > Free

등급 체계 설계

요청 우선순위 (Request Priority)

Priority Scheduler 사용

URGENT	즉시 처리 필요
HIGH	우선 처리
NORMAL	일반 처리
LOW	여유 처리

구독 등급 (Subscription Tier)

WFQ Scheduler · Rate Limiter 사용

Enterprise	가중치 100 분당 100건
Premium	가중치 50 분당 50건
Standard	가중치 10 분당 10건
Free	가중치 1 분당 5건

실험 결과 1: 알고리즘별 평균 대기시간

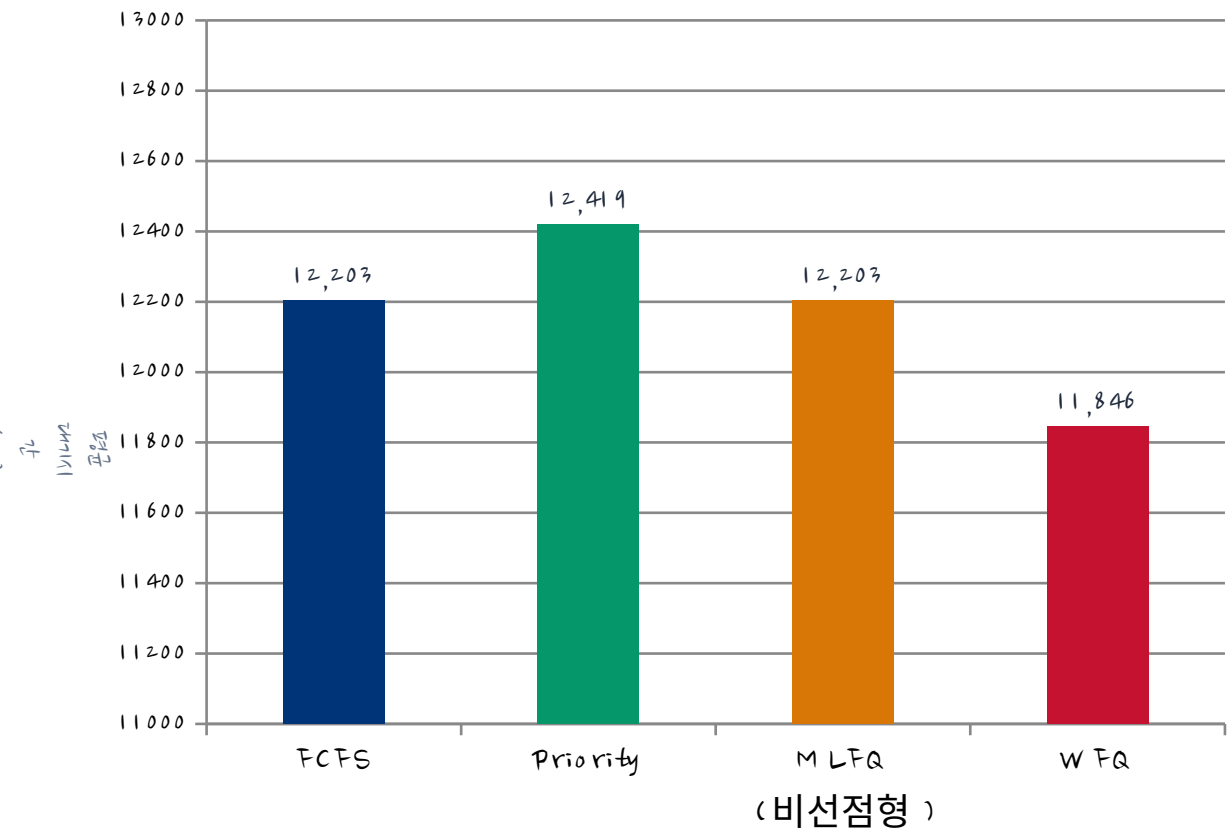

핵심 발견

! MLFQ(비선점형) = FCFS 동일 결과

✓ WFQ가 가장 짧은 평균 대기시간

→ 선점 없이는 큐 순서와 무관

* 시뮬레이션 500건, 처리시간 10~100ms 균등 분포

실험 결과 2: MLFQ 선점형 vs FCFS

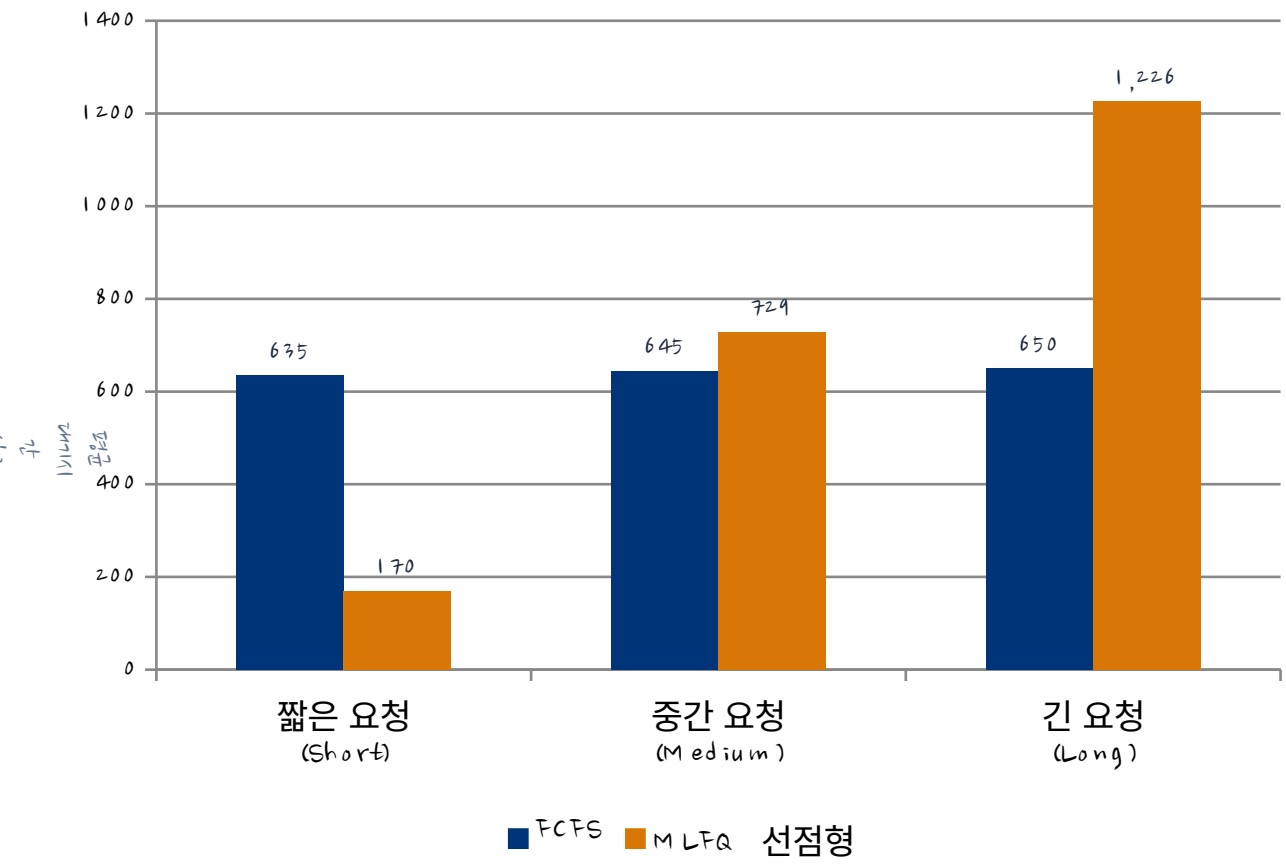

짧은 요청 대기시간

약 73% 감소

635초 ⟶ 170초

트레이드오프

Short	↓73%
Medium	↑13%
Long	↑89%

실험 결과 3: WFQ 구독 등급별 대기시간

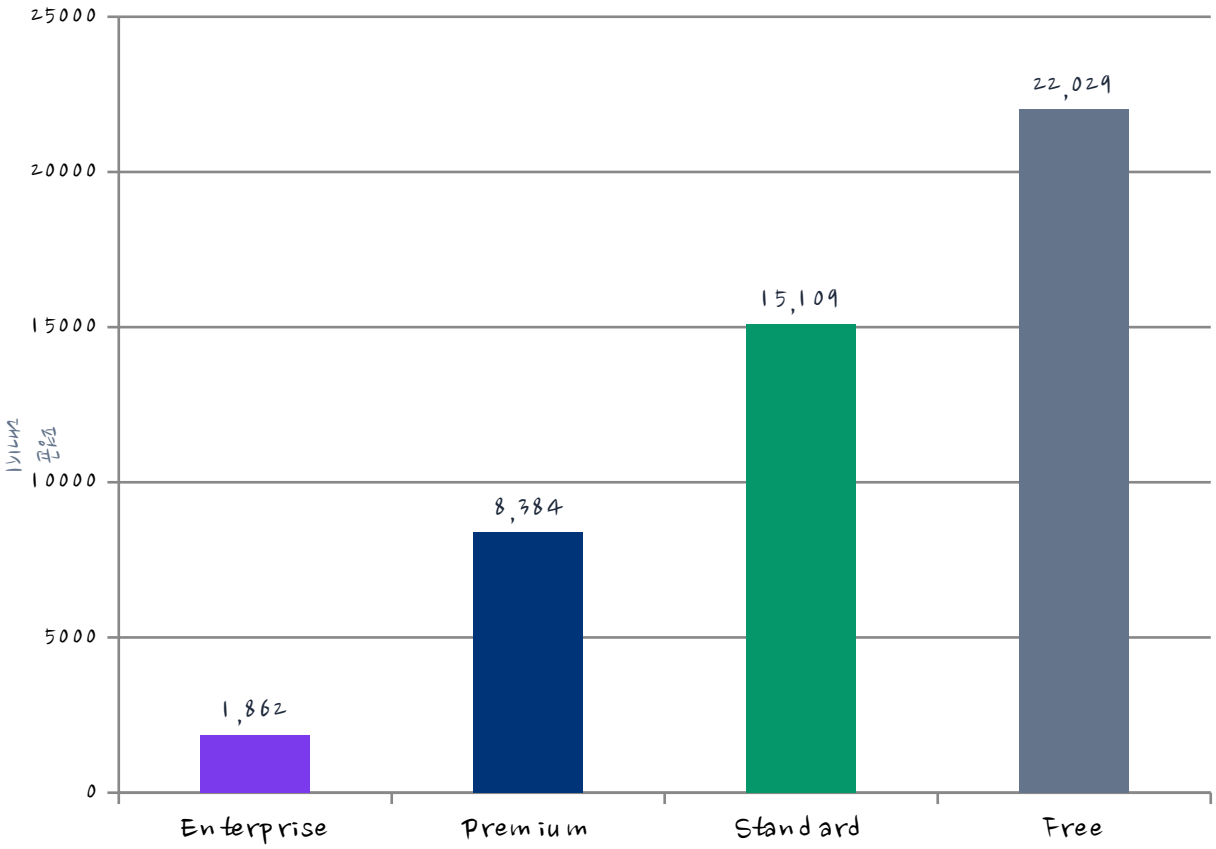

핵심 결과

Enterprise

약 1,862ms

vs

Free

약 22,029ms

약 12배 차이

가중치 비율에 비례한
차등 서비스 확인

실험 결과 4: 실서버(Ollama) 검증

시뮬레이션

- 처리시간: 10~100ms (미리 설정)
- 스케줄러: 처리 순서 결정
- 결과: 즉시 반환
- 선점형: 구현 가능
- 장점: 빠른 반복 실험

실서버 (Ollama LLM)

- 처리시간: 약 208ms (실제 추론)
- 스케줄러: 처리 순서 결정
- 결과: 실제 LLM 응답 생성
- 선점형: 불가 (추론 중단 불가)
- 장점: 실제 환경 검증

핵심 발견: 스케줄러는 처리 순서만 결정하며, 실제 LLM 추론 속도에는 영향을 주지 않습니다.
실서버 환경에서도 스케줄링 알고리즘이 정상 동작하였고, 선점형 구현은 실제 LLM에서 제약이 있습니다.

결론

RQ1

구현 가능성

4개 알고리즘 모두 구현 완료

ollama 실서버 연동까지 검증

RQ2

성능 비교

비선점형 환경에서 알고리즘 간 처리량은 유사

WFQ 평균 대기시간 최소, MLFQ 선점형은 짧은 요청 약 73% 감소

RQ3

공정성 분석

FCFS·Priority·MLFQ: JFI = 1.0 (완전 공평)

WFQ: JFI = 0.32 (의도적 차등)

한계 및 향후 과제

- 시뮬레이션 기반 실험 (실제 부하와 차이 가능)
- 선점형은 실제 LLM에서 적용 불가
- 향후: 토큰 기반 비용 모델 · 대시보드 고도화 · 등급 내 공정성 검증 · 대규모 실험

실시간 데모

http://localhost:3000

시나리오 1: FCFS vs WFQ 비교 (2분 30초)

① FCFS 서버 시작

② 4개 등급 요청 전송

③ 처리 순서 확인 (도착 순서)

④ WFQ로 전환 후 재전송

⑤ Enterprise 우선 처리 확인

시나리오 2: Rate Limiter 시연 (1분)

① Rate Limiter 활성화

② Free 등급 6개 요청 전송

③ 429 응답 확인 (한도 초과)

④ Enterprise는 정상 처리 확인

```
SCHEDULER_TYPE=WFQ node src-simple/server.js
curl -X POST http://localhost:3000/api/requests -H "Content-Type: application/json" \
  -d '{"prompt":"Hello","tenantId":"enterprise","tier":"enterprise","priority":"HIGH"}'
```